

Scaling AI-Driven Market Share Estimation to Production

ARCHITECTURE, PIPELINES AND PRODUCTIZATION

Joan Bennàssar Martín


UPC: Ramon Sangüesa

Shalio: Magdalena Sztandarska

Barcelona, a 26 de juny de 2026

Market Share

Estimació de vendes (o % de vendes) d'un producte o marca dins una categoria concreta d'una store en una setmana.





2,000+

retailers across the
globe



1,100+

websites scraped daily




160+

mobile apps monitored
worldwide



95

food service
aggregators tracked
worldwide




Digital Shelf Maestro

Amazon Shelf Maestro

Retail Media Maestro

Outlet Distribution Maestro



Data Sources

1-24 of over 3,000 results for "Soda Soft Drinks"

Eligible for Free Shipping

- ☐ Free Shipping by Amazon
- ☐ Get FREE Shipping on eligible orders shipped by Amazon

Prime Delivery

- ☐ Today by 5PM
- ☐ Overnight by BAM

Delivery Day

- ☐ Get It Today
- ☐ Get It by Tomorrow

Pick Up

- ☐ FREE Pickup

Brands

- ☐ Pepsi
- ☐ Dr. Pepper
- ☐ Coca-Cola
- ☐ Mountain Dew
- ☐ Sprite
- ☐ Diet Coke
- ☐ Fanta

See more

Soft Drink Type

- ☐ Caffeine-Free
- ☐ Cane Sugar
- ☐ Sugar-Free

Customer Reviews

★★★★☆ & Up

Sponsored

SNAP EBT Eligible

Price

\$0 - \$280+

Reviews

Units sold

Deals & Discounts

All Discounts

Results

Check each product page for other buying options.

Pepsi Cola Soda, 12 Fl Oz Cans (Pack of 12)

Options: 4 Flavors

4.5 ★★★★★ (18,755)

30K+ bought in past month

\$8¹⁹ (\$0.06/fluid ounce) Typical: \$15.99

SNAP EBT eligible

Join Prime to get FREE delivery Mon, Jun 8

Or Non-members get FREE delivery Wed, Jun 10 on \$35 of items shipped by Amazon

Add to cart

Pepsi Zero Sugar: Cola Soda, Wild Cherry, 12 Fl Oz Cans (Pack of 12)

Options: 4 Flavors

4.5 ★★★★★ (17,101)

20K+ bought in past month

\$10¹⁹ (\$0.07/fluid ounce)

SNAP EBT eligible

Join Prime to get FREE delivery Mon, Jun 8

Or Non-members get FREE delivery Wed, Jun 10 on \$35 of items shipped by Amazon

Add to cart

Slice Orange Healthy Soda, With Prebiotics and Probiotics, 12 fl oz Can

Options: 8 Flavors

4.5 ★★★★★ (8,071)

40K+ bought in past month

\$2⁹⁹ (\$0.25/fluid ounce)

SNAP EBT eligible

\$12.99 delivery Today 2PM - 6PM

Only 8 left in stock - order soon.

Add to cart

Coca-Cola Fridge Pack Soda Soft Drink, 12 fl oz Cans, 12 Pack - Classic Cola Soda Cans

Options: 2 sizes, 2 Flavors

4.5 ★★★★★ (16,561)

50K+ bought in past month

\$8⁴² (\$0.06/fluid ounce)

Save \$5.25 on 3 select items

SNAP EBT eligible

Join Prime to get FREE delivery Mon, Jun 8

Or Non-members get FREE delivery Wed, Jun 10 on \$35 of items shipped by Amazon

Add to cart

Coca-Cola Zero Sugar Soda, 12 fl oz Cans, 12 Pack - Classic Cola Soft Drink Fridge Pack

Options: 2 sizes, 2 Flavors

4.5 ★★★★★ (10,041)

40K+ bought in past month

\$8⁴² (\$0.06/fluid ounce)

Save \$5.25 on 3 select items

SNAP EBT eligible

Join Prime to get FREE delivery Mon, Jun 8

Or Non-members get FREE delivery Wed, Jun 10 on \$35 of items shipped by Amazon

Add to cart

Source 1: Product Listing Page - PLP (seed)

Lavazza, Qualità Oro, Café en Grano Natural, Ideal para la Máquina de Café Espresso, con Notas Aromáticas de Frutas y Flores, 100% Arábica, Intensidad 5, Tueste Medio, Paquete de 1 kg

Visita la tienda de Lavazza

4.5 ★★★★★ (45,558) | Buscar en esta página

Opción Amazon

4 características de sostenibilidad

4 mil+ comprados el mes pasado

-12 % 29⁹⁰ € (29,50€ / kg)

Precio recomendado: 33,50€ / kg

Los precios incluyen cualquier IVA aplicable. Leer más

Ahorra 5 % en cada \$ o más Comprar artículos seleccionados

Sabor: Qualità Oro

Classico	Espresso	Espresso Barista...	Qualità Oro	Sin sabor
30,00€ Tiempos locales	23,78€ \$3,60€	32,78€ (\$2,78€ / kg) \$4,09€ Tiempos locales	28,60€ (\$2,30€ / kg) \$3,60€ Suscríbete y...	28,60€ (\$2,30€ / kg) Tiempos locales

Tierra for Planet

33,29€
(\$3,29€ / kg)
Tiempos locales

Ver 2 opciones sin ofertas destacadas

VARIANTS

Compra recurrente

29⁹⁰ € (29,50€ / kg)

Activa la compra recurrente y ahorra hasta un 5%.

- Sin coste adicional
- Envío gratuito
- Cancela cuando quieras

Más información

Entrega GRATIS el miércoles, 26 de noviembre. Haz el pedido en 6 horas 19 mins. Ver detalles

En stock

Cantidad: 1

Suscríbete

Entrega cada: 2 meses (Más común)

Remite / Vendedor

Devoluciones

Suscripción

Sin tarifas. Omite o cancela en cualquier momento.

BUYBOX


Compra única

Source 2: Product Detail Page - PDP



Source 3: Vendor Central, Dades Ground Truth

Market Share a Shalion



Motivacions del treball

1 - Fer funcionar el mòdul de predicció a escala per RMM (enginyeria)

4
retailers

+20.000
seeds

>500.000
queries

>12h
d'execució

\$378 i
*sense
output*

2 - Millorar precisió per a clients específics (modelatge)

Objectius

- 1 - Nova estratègia de recol·lecció de dades (setmanes naturals Dll-Dg)
- 2 - Eliminar el coll d'ampolla de queries → producció setmanal viable
- 3 - Migració a Apache Iceberg
- 4 - Refactorització i noves pipelines
- 5 - Revenue proxy per agregar subcategoria → categoria

1 - Nova estratègia de recollecció de dades

DLL	DM	DMC	DJ	DV	DS	DG
DLL	DM	DMC	DJ	DV	DS	DG


Període estimat

Extracció PLP/BSR: Snapshot per a inferència

Execució DAG: Run setmanal de producció

Date tolerance: si no hi ha dades per al dia exacte, s'obre una finestra $\pm N$ dies


2 - System 0



Pipeline Complete

Pipeline (parallel, per seed)

Cloud storage



>500.000
queries

>12h
d'execució

L'execució
no acaba

Fargate
task


Pipeline
Complete

Pipeline
step


DB queries

S3 output

2 - New Architecture



Airflow DAGs



Parent DAG

2 - System 1

Optimitzar el codi del pipeline:

- Refactor taula DBT de input
- Reduir de +20 a 1-3 queries per seed a snowflake
- Partir el client RMM en lots de 200 seeds (fargate tasks independents)

**~60.000
queries**

**2,5-3h
d'execució**

**Segueixen
els
encuaments**

**\$196
setmana**


Pipeline Complete

Pipeline (parallel, per seed)

Cloud storage

2 - System 2

- Una única query per client
- Client RMM en lots de 2500 seeds (memòria)



*Tantes
queries com
clients*

*~1h
d'execució*

Fargate
task


Pipeline
Complete

Pipeline
step

Bulk query

S3 output

3 - Migració a Apache Iceberg



4 - Sistema de 9 Tiers

Cada seed va a la pipeline adequada als seus senyals disponibles (tier)

Tier	Amazon	Rank	Reviews / Ratings	NS	Actuals	Pipeline
1	yes	yes	—	yes	yes	1
2	yes	yes	—	yes	no	2
3	yes	yes	—	no	yes	—
4	yes	yes	—	no	no	—
5	no	yes	yes ($f^* > 0$)	—	—	3
6	no	yes	no ($f^* \leq 0$)	—	—	4
7	no	no	yes	yes	—	5
8	no	no	yes	—	—	5
9	no	no	no	—	—	5

4 - Pipelines 3 i 4 — Disseny i Entrenament

Pipeline 3 (Tier 5)


- rank absolut, log i relatiu
- reviews/ratings features

Pipeline 4 (Tier 6):

- rank absolut, log i relatiu

Target: $\log(\text{market share}) \rightarrow$ Duan's smearing correction

Entrenament: XGBoost + Optuna (50 trials) + GroupKFold ($k=5$, per execució)





4 - Resultats dels Models

Model	WMAPE (%)	R ²
Legacy (Pipeline 3)	101.4 (69.5)	0.23 (0.52)
New (Pipeline 3)	45.9 (26.2)	0.73 (0.92)


Comparació dels 4 models amb
només rank features

Model	WMAPE (%)	R ²
Legacy Pipeline 3	115.0 (79.6)	0.04 (0.38)
New Pipeline 3	106.1 (66.6)	0.48 (0.66)
New Pipeline 4	63.0 (37.5)	0.48 (0.83)
Baseline (1/N)	156.7 (107.3)	0.04 (0.09)

4 - Threshold Study




Decision boundaries: pip3 vs. pip4 (WMAPE-based)



5 - Revenue proxy intro

Motivació: Pipeline 3/4 produeix market share relatiu (suma 1 dins cada subcategoria). Com combinar subcategories sense saber la seva mida relativa?



Scraping leaf subcategories
captures ALL products (P1–P6)

Scraping only category PLP
misses P4, P5, P6

5 - Revenue proxy estudi

Revenue proxy = delta setmanal de ressenyes per producte

La hipòtesi: el % de ressenyes noves d'una subcategoria aproxima el % d'ingressos d'aquella subcategoria.

Date	N pairs	Correlation
2026-02-03	27	0.904
2026-02-10	16	0.954
2026-02-17	27	0.594
2026-02-24	16	0.977
Global (all dates)	86	0.818

5 - Revenue proxy implementation

$$MS_i^{(c)} = MS_i^{(s)} \times \frac{R_s}{R_c}$$

ASIN	Subcategory	Revenue proxy	Subcat. MS (model output)	Scaling factor R_s/R_c	Category MS (computed)
B00E22UKVG	Soft Drinks	400	0.70	800/1000 = 0.80	0.56
B000R9AK5O	Soft Drinks	300	0.25	800/1000 = 0.80	0.20
B000R9AKYU	Soft Drinks	100	0.05	800/1000 = 0.80	0.04
B01E6WOVX4	Water	150	0.60	200/1000 = 0.20	0.12
B089FLWNP3	Water	50	0.40	200/1000 = 0.20	0.08
<i>Check: category-level shares sum to</i>					1.00

Resultats

Architecture	DAG time	Snowflake cost	ECS cost
System 0 (original)	>12 h (timeout)	\$95	\$283
System 1 (intermediate)	2–3 h	\$41	\$155
System 2 (current)	≈ 1 h	\$32	\$82
Reduction (S0 $\rightarrow$ S2)	>12$\times$	66%	71%

Qualitat dels nous models

P3: 101% $\rightarrow$ 46% WMAPE

P4: 115% $\rightarrow$ 63% WMAPE

Carbon footprint:

S1: 2,78 kg CO₂e/setmana

S2: 0,09 kg CO₂e/setmana (-97%)



Organització i costos


Organització

- Dailys
- Planificació setmanal
- Reunions entre equips
- Metodologia àgil (Kanban)

Costos personal

- FIB - 540 hores x 10€ = 5400€
- Senior Data Scientist
- Equip d'Operacions
- Data Engineer
- Equip de Producte
- Equip de Visualització
- Customer Success

Costos infraestructura (execució setmanal)



Limitacions

⚠ **Ground-truth escàs:** Vendor Central disponible sols per seeds Amazon de clients específics. Avaluació limitada al subset ric. Pipeline 3/4 entrenen sobre pseudo-labels de P1 — hereten els seus biaixos.


⚠ **Coverage gap Tiers 3/4:** Seeds Amazon amb rank però sense NS → cap output. Afecta Amazon fora dels EUA (DE, ES, IT...).

⚠ **Migració Iceberg pendent:** Concurrent-write blocker no resol't. El sistema segueix dependent d'External Tables amb refresh manual (DAG)

⚠ **Revenue proxy validat parcialment:** L'estudi de correlació és sobre seeds d'Amazon (P1/P2). Extrapolació a non-Amazon (P3/P4) pendent de validació directa.

Conclusions

Del prototip a producció



Treball futur



Forecasting

Passar d'explicar el passat
a predir ventes de
setmanes futures

A → B



Causalitat


Entendre el “per què” per
tal de poder medir impacte
ral de preus, ads, stock...




Expansió ground truth

Incorporar nous socis i
clients per reduir la
dependència
semi-supervisada.

Reflexió Personal



Mentalitat acadèmica



Mentalitat industrial

Moltes gràcies

Barcelona, a 26 de juny de 2026